Introdução a Paralelização de Aplicações com OpenMP

Luan Teylo[1] e Lúcia M. A. Drummond[2]

[1] *INRIA Bordeaux - TaDaaM*
[2] *Fluminense Federal University - IC/UFF*

Escola Regional de Alto Desempenho do Rio de Janeiro 2021

Luan Teylo (Foto ilustrativa)

- Bacharel em Ciência da Computação (UFMT - 2015)
- Mestrado em Computação (UFF - 2017)
- Doutorado em Computação (UFF - 2021)
- Pós doutorado (Inria Bordeaux - Atual)

Sobre esse minicurso

- IV DevWeek 2016 (Leonardo Araujo e Luan Teylo)
- ERAD-RJ 2017 (Leonardo Araujo e Luan Teylo)
- ERAD-RJ 2018 (Rodrigo Alves)
- ERAD-RJ 2020 (Luan Teylo)

Códigos disponíveis em:
`https://github.com/luanteylo/minicurso-OpenMP`

Não importa o quão rápido os computadores são. Neste momento, novas tecnologias estão sendo desenvolvidas para que eles sejam ainda mais rápidos. Nosso apetite por processamento e capacidade de memória parece insaciável.

Chapman *et al.* (2008)

Quase duas décadas de evolução gráfica do jogo Tomb Raider (1996 à 2013).

A indústria dos jogos eletrônicos é um exemplo "visual" da demanda **constante** por mais capacidade de processamento.

Paralelismo

Na década de 1980 várias fornecedores começaram a produzir computadores que exploravam um paralelismo arquitetural. As máquinas eram construídas com **vários processadores completos** que **compartilhavam** a mesma memória principal.

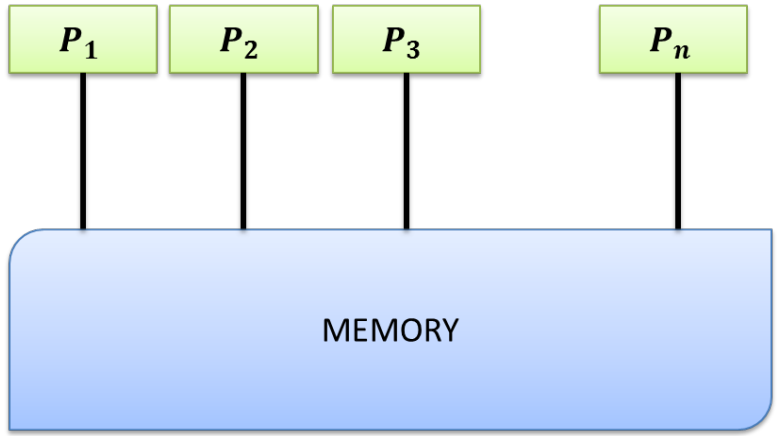

Arquitetura de memória compartilhada.

O Processo de Programação Paralela

Problema Original

O Processo de Programação Paralela

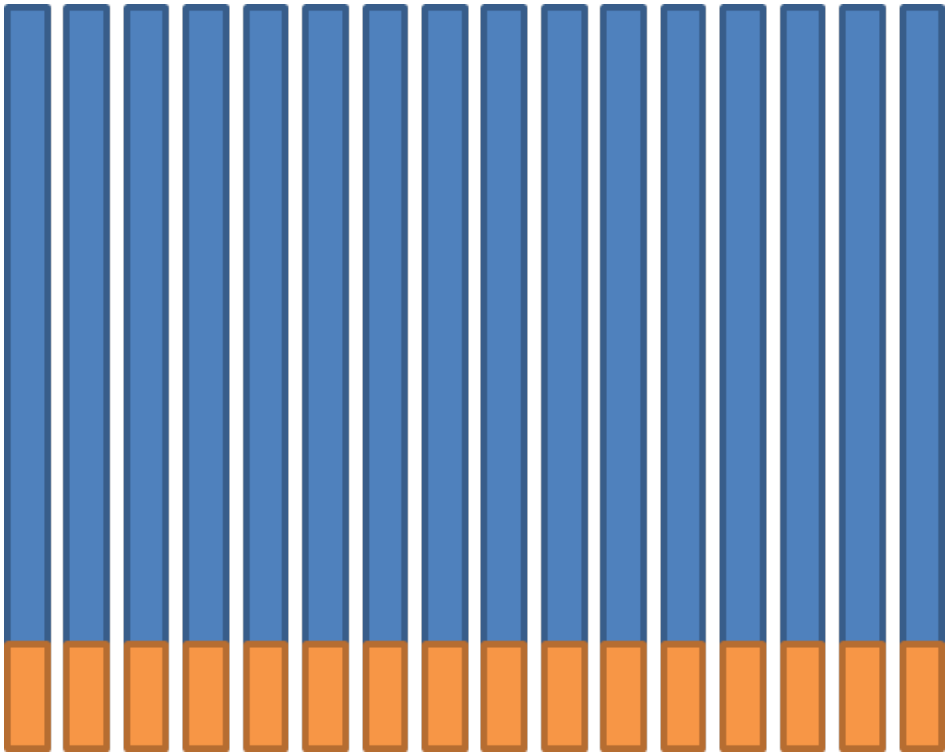

Definir paralelismo

O Processo de Programação Paralela

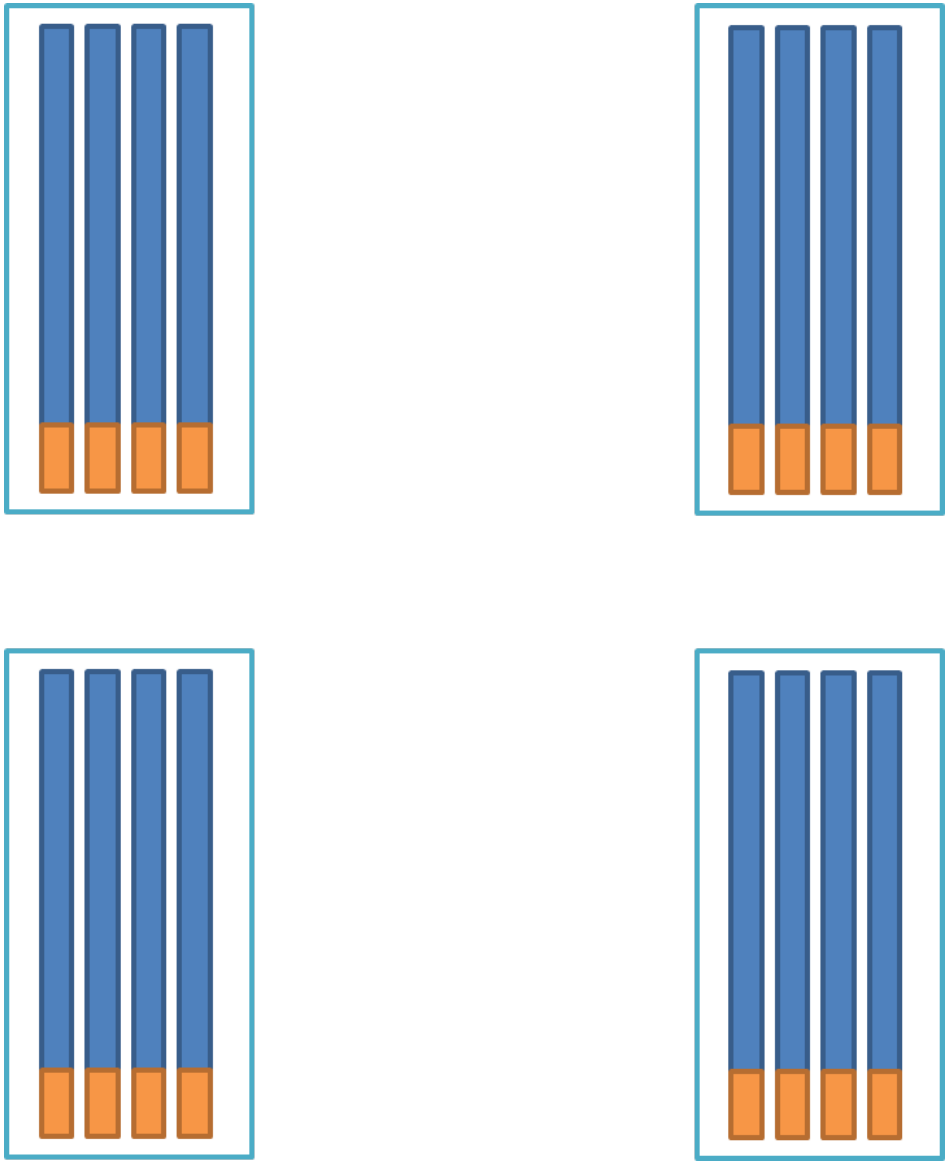

Estratégia Algorítmica

Por que deveríamos paralelizar?

- Quantos cores tem o seu computador?
- Os programas que você escreve aproveitam TODO o poder de processamento disponível?
- Você quer ganhar desempenho?

Paralelismo

Expectativa

Programas cada vez mais rápidos aproveitando todos os processadores

Paralelismo

Realidade:

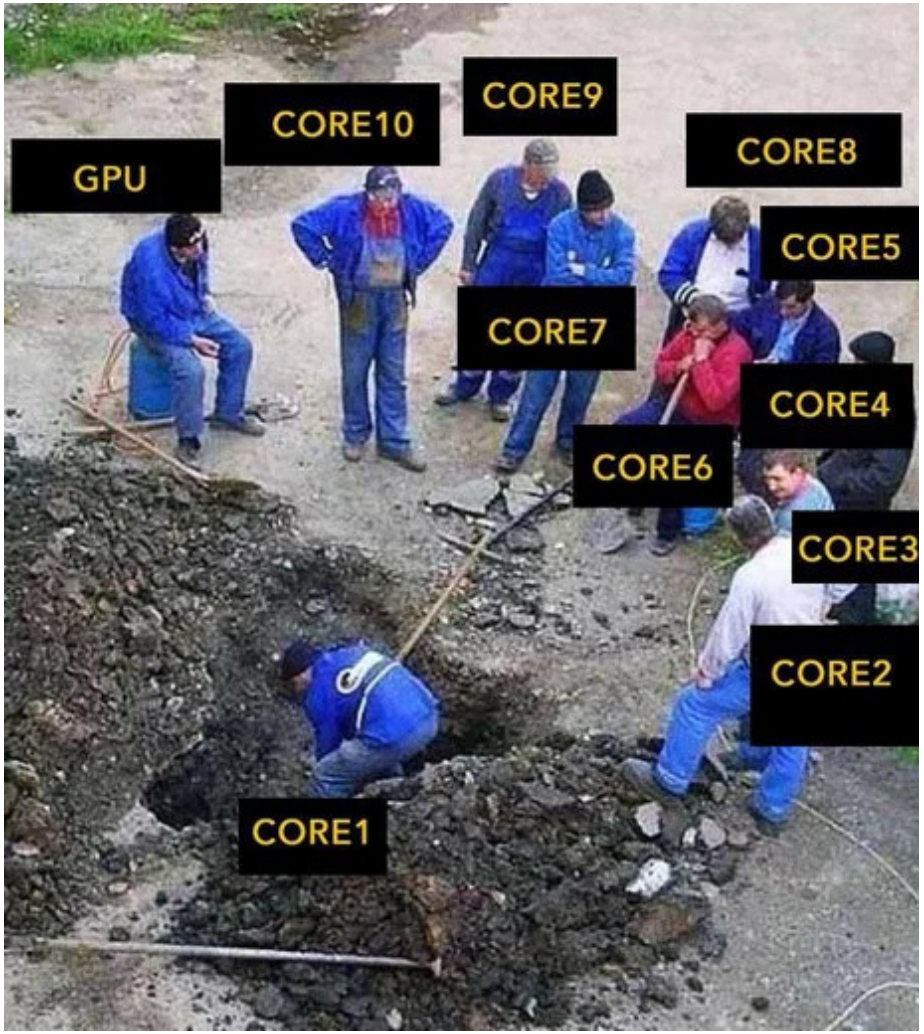

Introdução ao OpenMP

Open specification for Multiprocessing

O que é OpenMP?

- API de programação multithreading com memória compartilhada
- Especificação colaborativa: indústria, governo e academia
- Composto por Diretivas, Funções e Variáveis de Ambiente
- http://www.openmp.org/

Sobre OpenMP

- Linguagens suportadas: Fortran e C/C++
- Mesmo código para implementação serial e paralela
- Implementação portátil e intuitiva
- Requer compilador (não é apenas uma biblioteca)

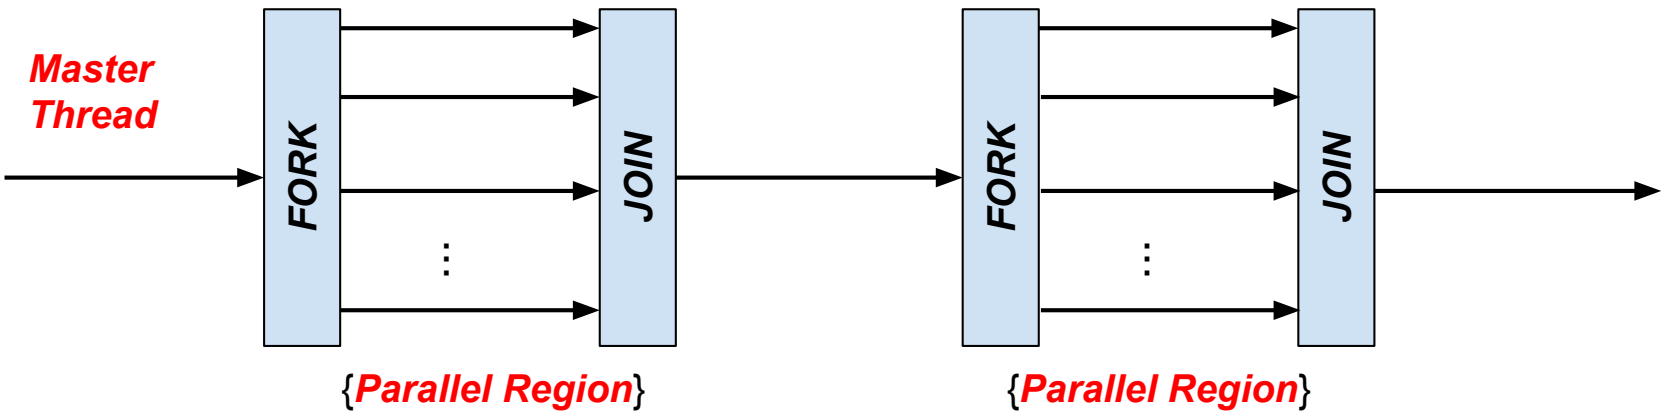

Principais Componentes do OpenMP

- Diretivas
  - *#pragma omp parallel*
  - *#pragma omp master*
  - *#pragma omp single*
  - *#pragma omp for*
  - *#pragma omp critical*
  - *#pragma omp atomic*
  - Etc
- Biblioteca
  - *omp_get_num_threads()*
  - *omp_set_num_threads()*
  - *omp_get_thread_num()*
- Variáveis de ambiente
  - OMP_NUM_THREADS

Expressando paralelismo

Bloco paralelo

- *#pragma omp parallel*
- Inicia bloco de código que será executado por todas as *threads* disponíveis

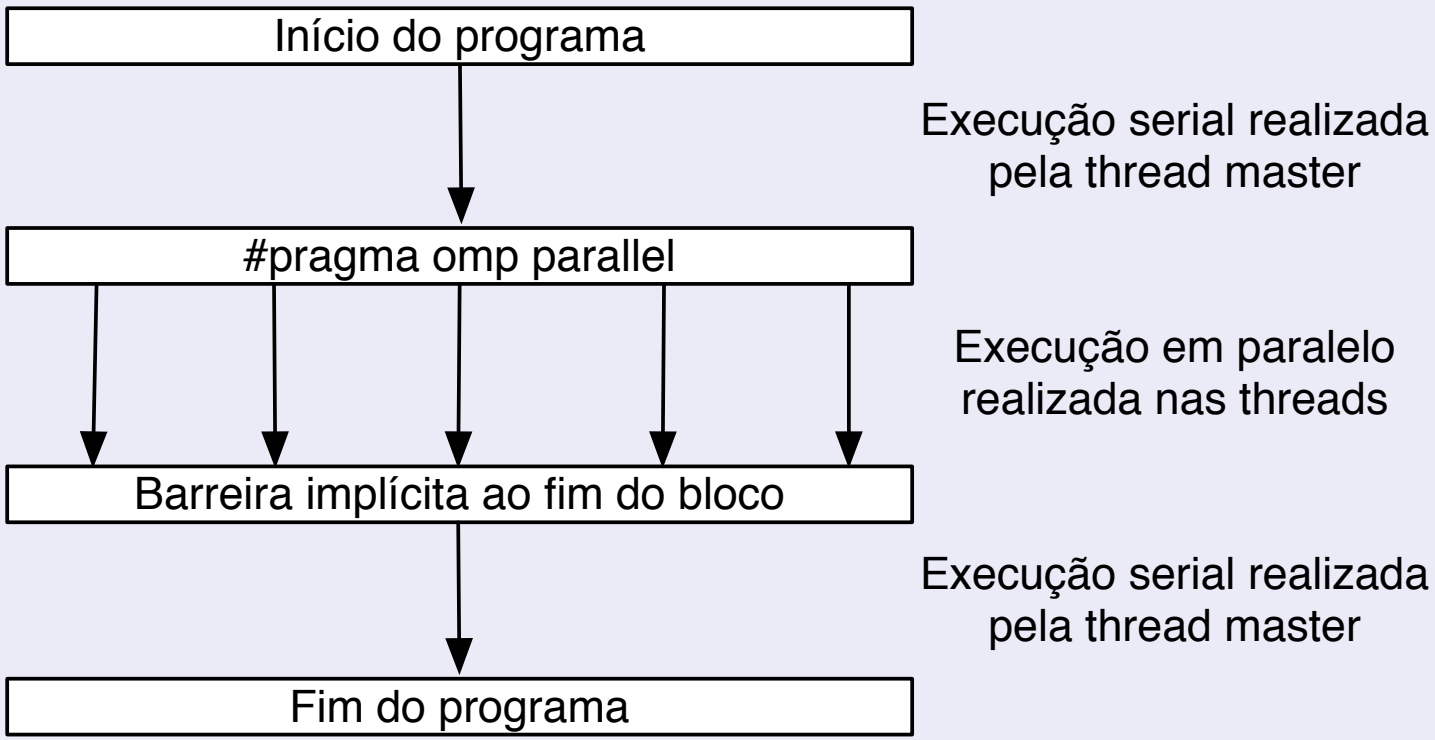

Exemplo

Hello World Paralelo

- A execução é inicializada na *thread master*
- A diretiva *#pragma omp parallel* inicia um bloco paralelo (*fork*)
- Cada thread executa os comandos contidos no bloco paralelo
- Barreira implícita ao fim do bloco (*join*)
- *Thread master* retoma o processamento serial

para compilar: *$ gcc -o hello -fopenmp hello.c*

Pergunta: O que acontece na linha 11?

Expressando paralelismo

Divisão de *loop*

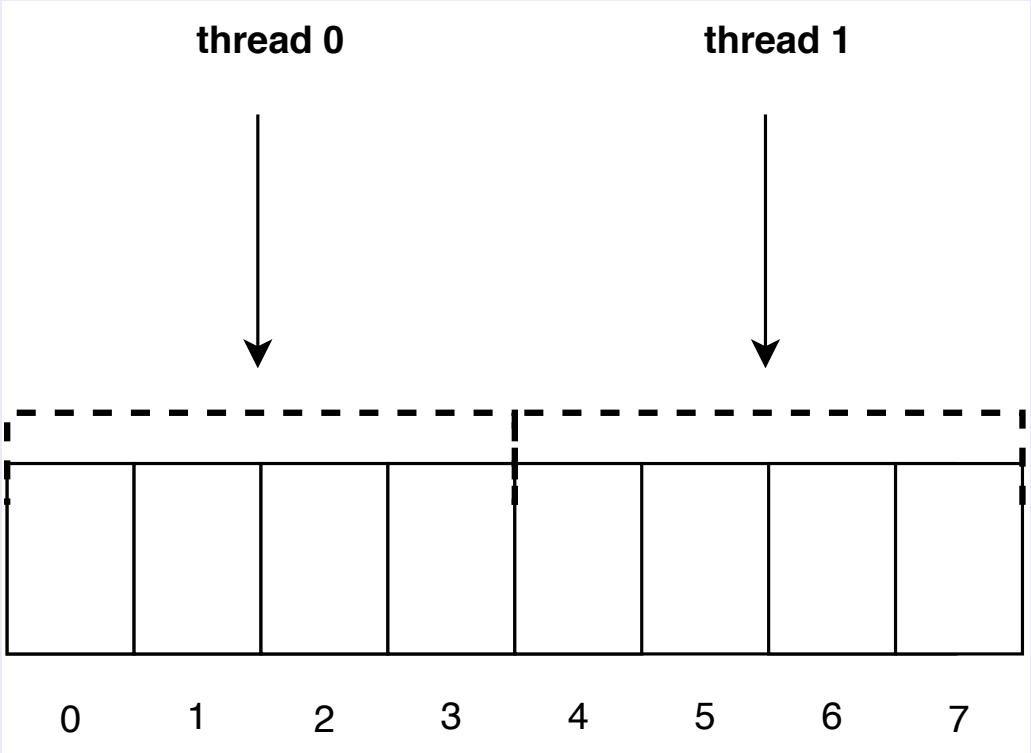

Expressando paralelismo

Divisão de *loop*

- *#pragma omp for*
- Divide as iterações de um *loop* entre as *threads* disponíveis

```
int i[10];
omp_set_num_threads(2);
```

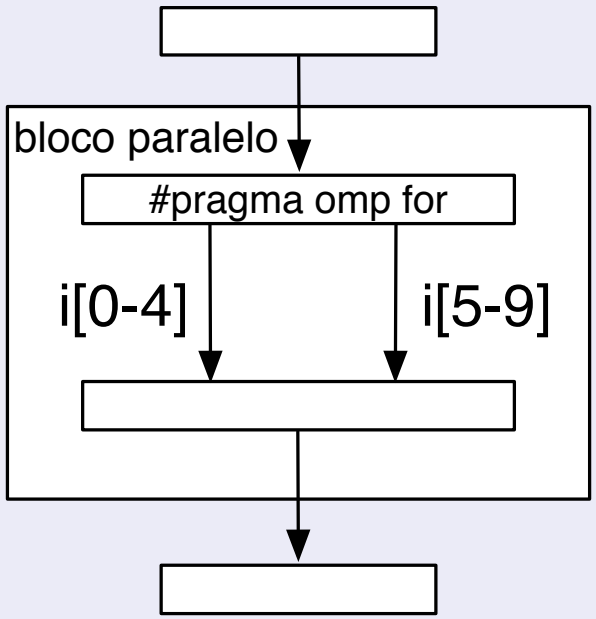

Contexto dos Dados

- Contexto das threads
  - Variáveis locais
  - Variáveis globais
- Variáveis privadas
  - Private
  - Firstprivate
- Variáveis compartilhadas
  - Default
  - Shared
- Redução
  - Reduction (+,-,*,MAX,MIN,etc)

Exemplo

Contexto de variáveis

- Inicialização da variável X
- Criação de 20 threads

Pergunta: O que acontece em cada um dos blocos paralelos?

Sincronização

Como estabelecer uma ordem na execução das *threads*?

Barreira

- *#pragma omp barrier*
- Todas as *threads* devem alcançar a barreira para que a execução possa seguir
- Garante consistência

Sessão crítica

- *#pragma omp critical*
- Trecho executado por somente uma *thread* por vez
- Garante exclusão mútua, evita condição de corrida

Exemplo

Redução de um vetor

- Dado um vetor de N posições
- Somar os valores contidos em cada uma das N posições

Pergunta: Como dividir este problema?

Exemplo

Contar números primos

- Dado um valor N
- Qual o número de primos no intervalo [1,N]?

Perguntas:

- Como dividir este problema?
- Esta solução está correta?
- Todas as *threads* terão o mesmo trabalho?

Escalonamento de Iterações

Escalonamento Estático

- Escalonamento default
- Chunksize default = número de iterações / número de threads
- *#pragma omp parallel for schedule(static[,chunksize])*

Escalonamento Dinâmico

- Chunksize default = 1
- *#pragma omp parallel for schedule(dynamic[,chunksize])*

Escalonamento Guiado

- Compilador define tamanho dos chunks, de forma decrescente
- Lastchunksize define o tamanho do último chunk
- *#pragma omp parallel for schedule(guided[,lastchunksize])*

Escalonamento de Iterações

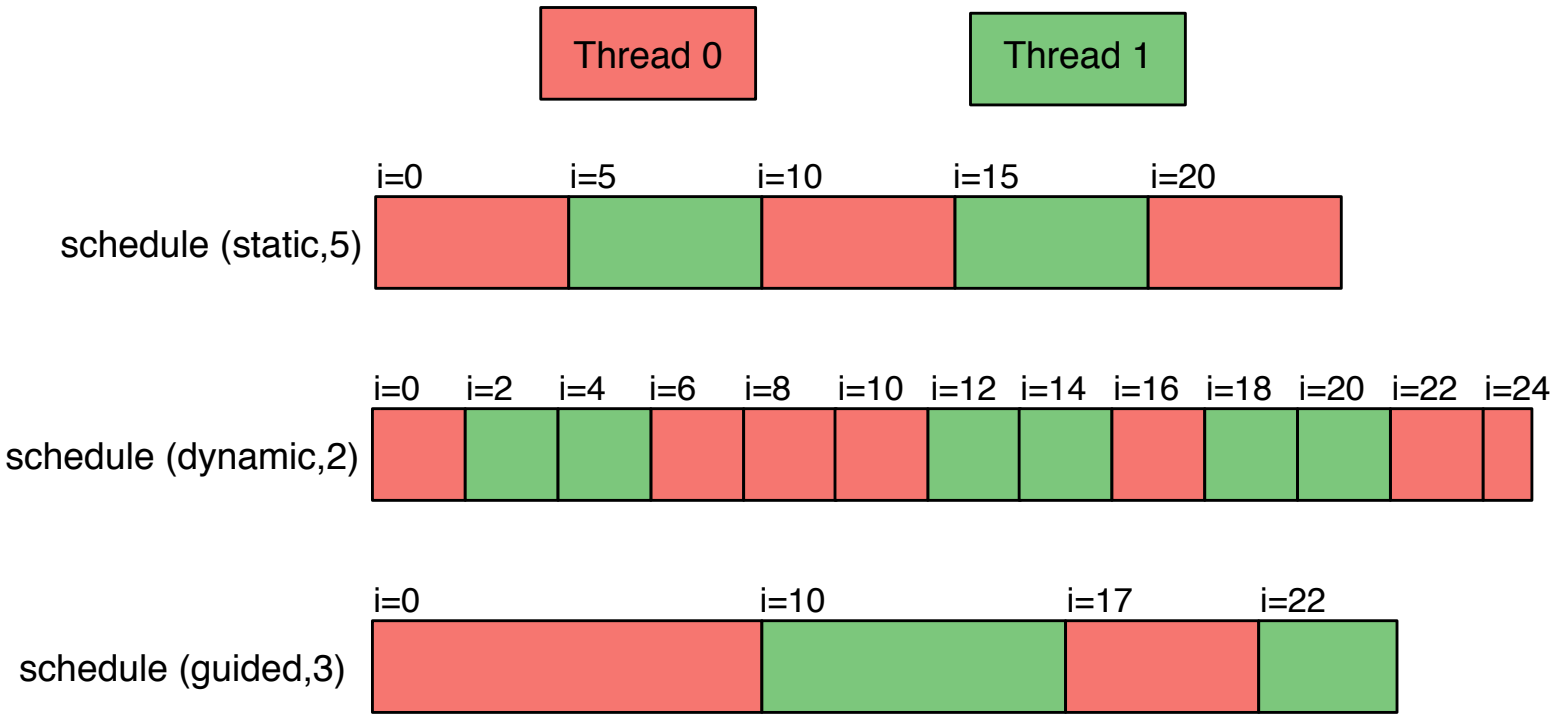

créditos

Minicurso produzido originalmente por:

- leonardoaj@ic.uff.br
- luanteylo@ic.uff.br